TELECOM SudParis

Projet Informatique 1ère année
PRO 3600

Détection des styles architecturaux par une Intelligence Artificielle

Membres du projet : Elliot Cole, Brun Baptiste, Naama Mohamed, Abri Saad, Mateo Zoughebi

Mohamed Sellami PRO 3600- Département INF

Version 18/02/2022

Table des matières

Introduction

Ce document décrit le développement de l'application *Scan'INT* permettant l'identification de styles architecturaux sur une photo, dans le cadre du module PRO 3600. Le développement de l'application implique deux domaines d'étude: L'Intelligence Artificielle (IA) et la création d'une application web. Dans le cadre de ce projet nous nous restreindrons à l'identification de 25 styles architecturaux pour la création de l'IA.

2 Cahier des charges

2.1 Partie application web (front-end):

- *Fonctionnalités :*

L'application aura pour but principal de scanner un bâtiment de sorte à obtenir son style architectural.
Cette application web aura:

- Une interface dynamique qui propose à l'utilisateur d'ajouter une photo d'un bâtiment depuis son explorateur de fichiers
- A partir de cette photo, l'analyser et sortir en réponse le style architectural du bâtiment que prédit le réseaux de neurones en 'back-end"

- *Contrainte:*

    - Apprentissage du langage de programmation : HTML/CSS/JavaScript
    - Gestion de l'Intelligence artificielle depuis l'application web via un serveur python par la bibliothèque Flask

- *Livrable* **:**

    - Application web développée en JavaScript en local.

2.2 Partie IA

- *Contraintes :*

    - Apprendre de façon complète un langage de programmation: Python avec les bibliothèques suivantes : fastai (torch, torchvision), numpy, json, os, random,matplotlib. Ainsi que le NoteBook collaboratif : GoogleColab
    - Constitution d'une base de donnée assez large pour pouvoir entraîner notre IA (database trouvé sur Kaggle)

- *Fonctionnalités :*

    - Pouvoir reconnaître le style architectural d'un bâtiment (dans un premier temps un édifice religieux puis un plus large panel d'applications) à partir d'une photo envoyée par l'utilisateur sur l'application web.

- Livrable :
    - Réseau de neurones convolutifs fonctionnel sous Python à l'aide de Fastai.

3) Développement

Conception préliminaire

A haut niveau, le logiciel se décompose en deux parties, une partie "front-end" : c'est la partie IHM de l'application, elle sera à terme une interface logiciel sur web écrite en JavaScript/HTM..

La partie "back-end" est notre réseau de neurones convolutifs qui permettra de prédire l'architecture d'une photo que l'on enverra au programme.

Enfin une partie "intégration" sera mise en place pour faire le raccordement : ce sera un serveur python écrit en Flask

Les structures de données utilisées seront ici des images d'architectures que l'on trouvera sur https://www.kaggle.com/brsdincer/architecture-art-cyclegan-process/data . Elles seront ensuite adaptées au format 224x224 pixels par souci d'homogénéité.

Ici un descriptif des modules de notre logiciel :

Partie Back-end :

Fichier Entraînement_IA_Bâtiment.ipynb

Importation des modules:

Tout d'abord on commence par l'importation des différents modules que l'on va utiliser, notamment la bibliothèque Fast AI.
Fast AI va nous permettre d'avoir des résultats plus rapidement en termes de DeepLearning.

Etude des données :

La deuxième partie nous permet de télécharger notre dataset via le site Kaggle. Cela passe donc par le téléchargement d'un token API qui permet à notre IDE de se connecter sur Kaggle. Ensuite il suffit d'extraire notre fichier, et spécifier l'emplacement son emplacement pour que notre environnement de travail puisse y avoir accès.

Augmentation de la base de données :

Une fois le dataset téléchargé et importé, on peut augmenter notre base de données. En effet, afin d'optimiser nos chances de réussite, il est nécessaire d'avoir une base de données conséquentes.
Pour cela il suffit d'appliquer des transformations "primaire" à l'image (inclinaison, rotation, symétrie…)

Constitution de notre réseau de neurone convolutifs :

On va utiliser un réseau de neurones largement utilisé et déjà pré-entraînés sur notre modèle : resnet34. Ce réseau de neurones convolutifs ayant 34 couches de neurones. Celui-ci s'entraîne sur notre dataset d'image augmentée.

Partie Front-end :

Fichier app.py

Le serveur python écrit en Flask sera composé des modules suivants :

Une fonction *validate_image(stream)* qui permettra de signaler un message d'erreur si l'utilisateur envoie une image du mauvais format (autre format que jpg etc.)

Une fonction home() lié à @app.route('/') : cette fonction retourne une template en sortie celle de home.html : chaque fois que l'utilisateur va sur le site il va se retrouver sur cette page

Une fonction upload_files() lié à @app.route('/app.html, methods=[POST]) : cette fonction s'exécute lorsque l'utilisateur envoie une requête POST, quand il clique sur upload une image, celle ci s'enregistre dans le repertoire courant

Une fonction def solutions() lié à @app.route("/analyze", methods=[POST]) qui permettra d'analyser la photo et de sortir la prédiction du bâtiment en sortie

Conception détaillée :

Pour la partie “**back-end**” (fichier Entrainement_IA_Bâtiment.ipynb), voici un descriptif détaillé des différents modules :

Outre l’importation des différents modules (fastai, matplotlib etc.), il faut se rend sur : https://www.kaggle.com/nomdutilisateur/account puis sur "Create New API Token".

La méthode de os upload permet d’importer le token kaggle.json :

```
uploaded = files.upload()
```

On crée le répertoire où l'on va mettre notre dataset

```
! mkdir -p ~/.kaggle/
! mv kaggle.json ~/.kaggle/
```

C'est le chemin, d'accès de notre dataset

```
chemin = Config.data_path()/'architecture'
chemin.mkdir(parents=True, exist_ok=True)
```

On télécharge le dataset

```
! kaggle datasets download -d wwymak/architecture-dataset
```

On s'assure que le dataset est bien téléchargé, en le voyant apparaître dans le répertoire de travail

```
os.listdir()
```

Une fois bien téléchargé, on le met dans le répertoire, en dézippant

```
! unzip -q -n architecture-dataset.zip -d {chemin}
```

Etude des données :

Nous allons utiliser le jeu de données Architecture de Zhe Xu, qui présente 25 styles d'architecture. Notre modèle devra apprendre à faire la différence entre ces 25 catégories distinctes.

```
os.listdir('/root/.fastai/data/architecture/arcDataset')
```

Le chemin de notre data set est celui ci-dessous :

```
chemin = '/root/.fastai/data/architecture/architectural-styles-dataset'
```

La première chose que nous faisons lorsque nous abordons un problème est d'examiner les données. Nous devons toujours bien comprendre la nature du problème et l'aspect des données avant de pouvoir déterminer comment le résoudre. Examiner les données signifie comprendre comment les répertoires de données sont structurés, quelles sont les étiquettes et à quoi ressemblent quelques exemples

d'images. Cela va permettre de sélectionner des images différentes, afin de s'assurer que nos résultats ne sont pas le fruit du hasard :

```
np.random.seed(42)
```

On va transformer nos images afin d'augmenter notre dataset, on en parlera plus tard :

```
tfms = get_transforms(do_flip=True, flip_vert=False, max_rotate=10,
max_zoom=1.1, max_lighting=0.2, max_warp=0.2, p_affine=0.75, p_lighting=0.75)
```

Affichage des images, et études brèves du dataset

Dans cet ensemble de données particulier, les étiquettes sont stockées dans le nom du dossier qui contient les images de chaque classe. Nous devrons les extraire pour pouvoir classer les images dans les bonnes catégories. La bibliothèque fastai à une fonction faite pour cela, “ImageDataBunch.from_folder”.

```
data = ImageDataBunch.from_folder(chemin, train=".", valid_pct=0.2,
        ds_tfms=tfms, size=224, num_workers=4, padding_mode='reflection',
bs=64).normalize(imagenet_stats)
```

On affiche 9 images de notre set aléatoirement :

```
data.show_batch(rows=3, figsize=(9, 9))
```

On regroupe les différentes catégories ensemble :

```
data.classes, data.c, len(data.train_ds), len(data.valid_ds)
```

Augmentation de notre base de donnée

La fonction 'get transforms' nous a permis d'obtenir plus d'images pour l'entraînement, dans ce cas nous avons 9588 images au lieu des 4979 de l'ensemble de données original.

Ceci est réalisé en faisant quelques changements aux images et en les traitant comme des images nouvelles.

Retournement (juste horizontal), zoom, lumière, rotation, etc...

```
def _plot(i,j,ax):
    x,y = data.train_ds[3]
    x.show(ax, y=y)
```

plot_multi(_plot, 3, 3, figsize=(8,8))

Apprentissage : Constitution de notre réseau de neurones convolutifs

Maintenant que notre dataset d'images à été traité, nous pouvons dès à présent l'utiliser pour entraîner notre première couche de réseaux de neurones convolutifs. Pour cela, on va utiliser un réseau de neurones largement utilisé et déjà pré-entraînés sur notre modèle : resnet34. Ce réseau de neurones convolutifs ayant 34 couches de neurones

Ici, on va utiliser la fonction "cnn_learner" de la bibliothèque pytorch : Elle prend en entrée l'objet "data" (qui est notre dataset traité et normalisé précedemment), le nom du modèle (resnet34) et les paramètres que l'on cherche à observer (ici "l'accuracy" (précision) et le taux d'erreur)

learn = cnn_learner(data, models.resnet34, metrics=[accuracy])

learn.fit_one_cycle(5) C'est cette fonction qui va appliquer à notre variable learn, un entraînement de 5 epochs (5 tours)

learn.save('stage-1-resnet34') Par la fonction .save() de f permet d'enregistrer le réseaux "learn" dans le répertoire courant

learn.export() Maintenant on exporte notre modèle dans le dossier root, il est entraîné et doit être utilisé sur des images tests
!cp /root/.fastai/data/architecture/export.pkl . #On le copie dans le répertoire courrant

image = open_image(imagetest.jpg') On ajoute manuellement, dans le répertoire courant, l'image que l'on veut prédire (à rénommer imagetest impérativement)

learn = load_learner(chemin) La méthode load_learner de fastai prend en paramètre un chemin et renvoie le modèle dans une variable learn

prediction,pred_idx,outputs = learn.predict(image) #la modèle d'instance predict(image) renvoie notre prédiction sous la forme d'un objet de la classe Prediction (bibliothèque fastai)
prediction.obj La méthode obj de prediction renvoie sous forme de string, la prédiction

Pour la partie “**intégration**” (fichier app.py), voici un descriptif détaillé des différents modules :

La fonction validate_image(stream) permet de de retourner une erreur si le format de l’image est différent de jpeg ou jpg :

```
def validate_image(stream):
    header = stream.read(512)
    stream.seek(0)
    format = imghdr.what(None, header)
    if not format:
        return None
    return '.' + (format if format != 'jpeg' else 'jpg')
```

La fonction too_large permet de rediriger l’erreur HTML “ErreroHandler 413”, on écrit à la place “File is too large” avec l’id de l’erreur

```
@app.errorhandler(413)
def too_large(e):
    return "File is too large", 413

#========================mise de l'image dans le
dossier============================
```

La fonction cette fonction retourne une template en sortie celle de home.html : chaque fois que l’utilisateur va sur le site il va se retrouver sur la page home.html:

```
@app.route('/')
def home():
    return render_template('/home.html')
```

La fonction index() est similaire à la fonction précédente, elle s'exécute lors d’une requête GET (c’est à dire lorsque l’utilisateur va rejoindre la page par URL) et renvoie vers le template de app.hmtl

```
@app.route('/app.html')
def index():
    files = os.listdir(app.config['UPLOAD_PATH'])
    return render_template('app.html', files=files)
```

La fonction upload_files() est executé lorsqu’il y a une requête POST c’est a dire lorsque le user upload une image, celle ci se retrouve dans le répértoire courant au niveau local.

```
@app.route('/app.html', methods=['POST'])
def upload_files():
    uploaded_file = request.files['file']
    filename = secure_filename(uploaded_file.filename)
    if filename != '':
        file_ext = os.path.splitext(filename)[1]
        if file_ext not in app.config['UPLOAD_EXTENSIONS'] or \
            file_ext != validate_image(uploaded_file.stream):
            return "Invalid image", 400
        uploaded_file.save(os.path.join(app.config['UPLOAD_PATH'], filename)
    return '', 204
```

La fonction analyze est exécutée lorsqu'il y a une requête POST c'est a dire lorsque le user clique sur Analyser, c'est la que la méthode prédiction est envoyé, par la méthode model.prediction de fastai. On retourne cette réponse sur JavaScript

```
@app.route('/upload', methods=["POST"])
def analyze():

        img = open_image(io.BytesIO(file)) #On met l'image dans le bon format pour
que le model puisse l'utiliser
        prediction = model.predict(img)[0]

        response = {"result": str(prediction)}
        return jsonify(response)
```

Pour la partie "**front-end**" (fichier home.html, home.css, app.html, app.css, dropzone.js), voici une présentation du site :

La légende des photos ci-dessous fait référence aux nom de class/balises utilisées dans le code HTML/CSS.

- **Page d'accueil : (home.html + home.css) :**

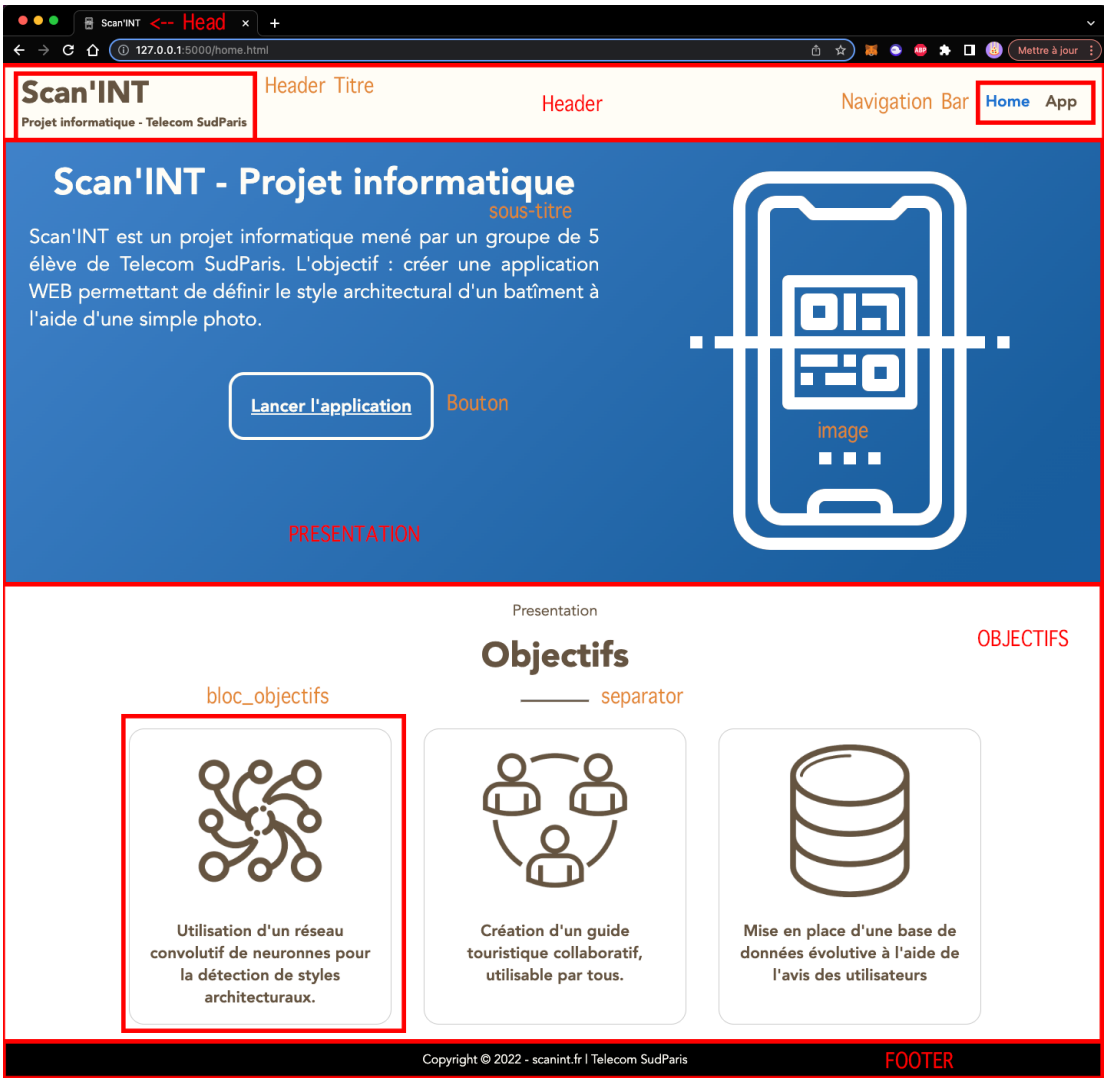

Sur cette page, on peut trouver une brève présentation de Scan'INT ainsi que les 3 principaux objectifs de l'application. On y trouve aussi une "navigation bar" qui permet de naviguer entre les deux pages du site : la page d'accueil 'home' et la page application 'App'. On peut aussi rejoindre cette seconde page à l'aide du bouton "lancer l'application" qui renvoie lui aussi sur la page application.

- **Page Application : (app.html + app.css + dropzone.js)**

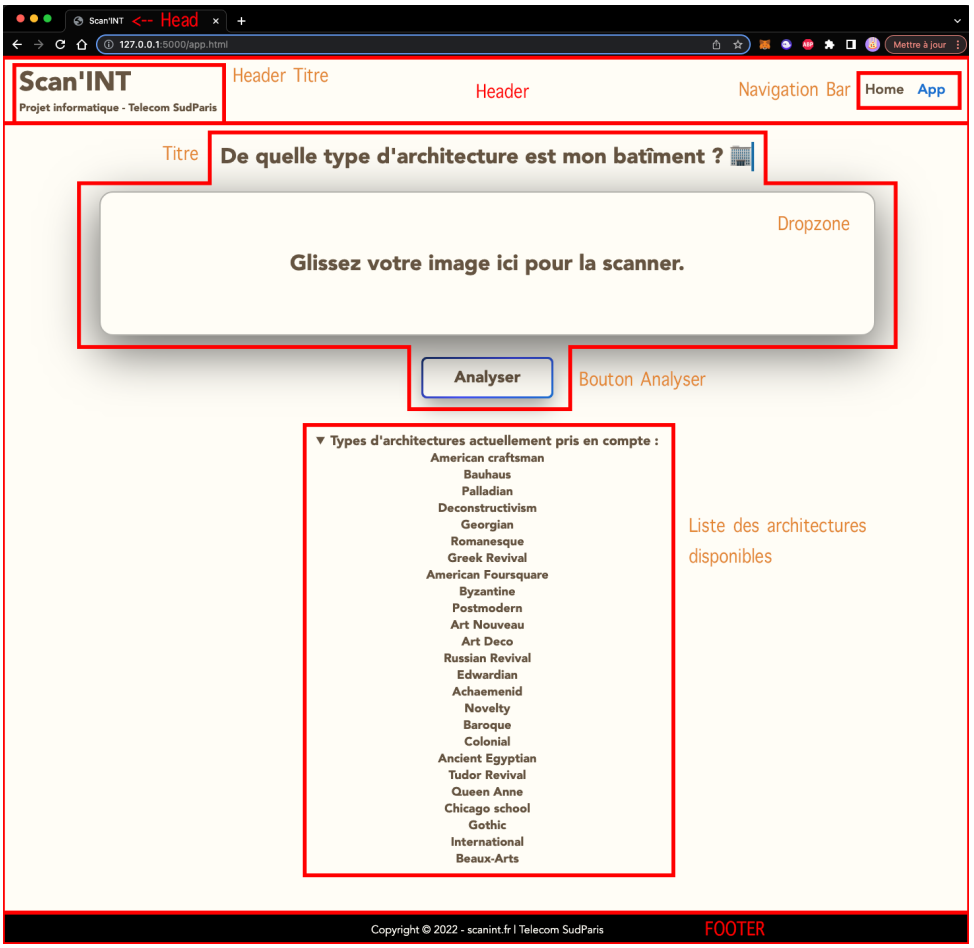

Sur cette page se trouve le coeur du projet, l'application web.
On y retrouve :

- le header avec la même navigation bar que sur la page d'accueil
- un titre animé qui rappelle la problématique à laquelle l'application tente de répondre
- une "dropzone", zone dans laquelle l'user pourra déposer l'image à étudier. Cette image est automatiquement transférée dans un dossier local de l'utilisateur nommé "upload" qui est ensuite utilisé pour la partie prédicition par l'IA.
- un bouton analyser, qui lance donc le scan de la photo qui a été préalablement téléchargée dans la dropzone par l'user
- une liste déroulante récapitulant tous les types d'architectures actuellement pris en charge par l'application

Le fichier “dropzone.js” permet notamment au site d’afficher quel fichier a déjà été téléchargé, quel type de fichier on peut utiliser, et bloque l’user lorsqu’il essaye d’en télécharger plus d’un :

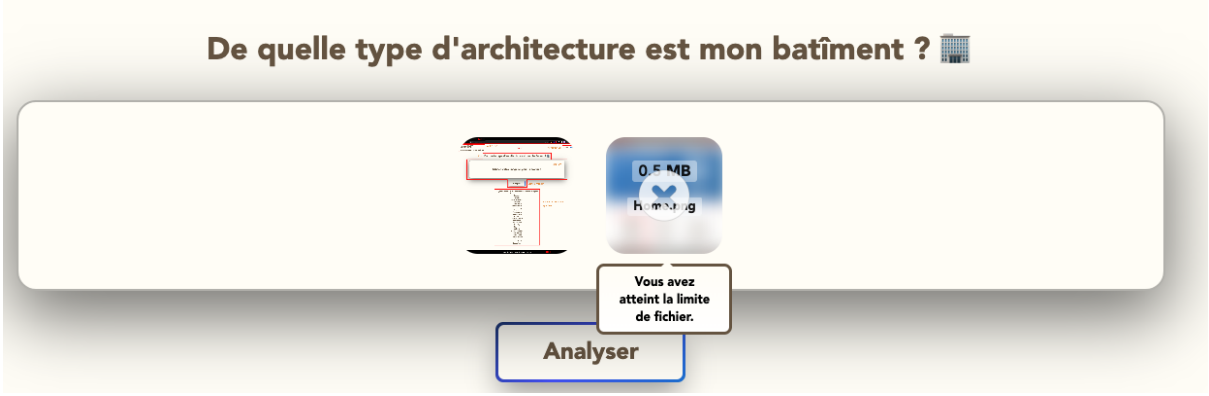

Le code source du site se trouve sur le gitlab, dans les dossiers templates (.html) et static (.css / .js).

Codage :

Les codes sources commentés des parties “back-end” et “front-end” ainsi que “integration” sont disponibles dans l’annexe (cf annexe)

Tests unitaires:

Pour le fichier Entrainement_IA_Bâtiment (2).ipynb :

Nous avons opéré plusieurs tests unitaires afin de déterminer si le réseau de neurones fonctionne correctement et est sans bug, à quel point il est efficace et combien de bonnes prédictions permet-il de faire.

La méthode *learn.fit_one_cycle* dans notre exemple a été entraînée sur 4 “epochs”, selon le CPU, le réseau apprend en 18 minutes et 43 secondes. De plus, on arrive a une précision allant jusqu’à 79%. On remarque aussi que la fonction de coût des jeux de données de validation et d’entraînement diminue de tours en tours, ce qui est bon signe (moins en moins de mauvaises prédictions).

Epochs = nombre de "tours" du réseaux de neurones que le modèle fait
Valid_loss = résultat de la fonction de coût sur le jeu de données de validation
Train_loss = résultat de la fonction de coût sur le jeu de données d'entraînement
Accuracy = précision du modèle : c'est la proportion de bonnes prédiction
Time = temps pour chaque epoch

epoch	train_loss	valid_loss	accuracy	error_rate	time
0	2.183656	1.135984	0.670840	0.329160	04:42
1	1.321748	0.896148	0.728743	0.271257	04:39
2	1.007899	0.704236	0.782994	0.217006	04:40
3	0.814357	0.672641	0.790297	0.209703	04:42

```
/usr/local/lib/python3.7/dist-packages/torch/utils/data/dataloader.py:481: UserWarning: This DataLoader
  cpuset_checked))
```

On va utiliser les méthodes de tests suivantes pour approfondir :
interpretation = ClassificationInterpretation.from_learner(learn) La bibliothèque fastai fournit la classe ClassificationInterpretation, on crée notre objet.
interpretation.plot_confusion_matrix(figsize=(12,12), title = "Matrice de confusion", cmap = "YlOrRd", dpi=70) Méthode d'instance permettant d'afficher la matrice de confusion, le coefficient (i,j) de cette matrice affiche combiens de fois le j-ème élément a été prédit alors que la véritable valeur était le i-ème élément.

On obtient ainsi la matrice de confusion suivante :

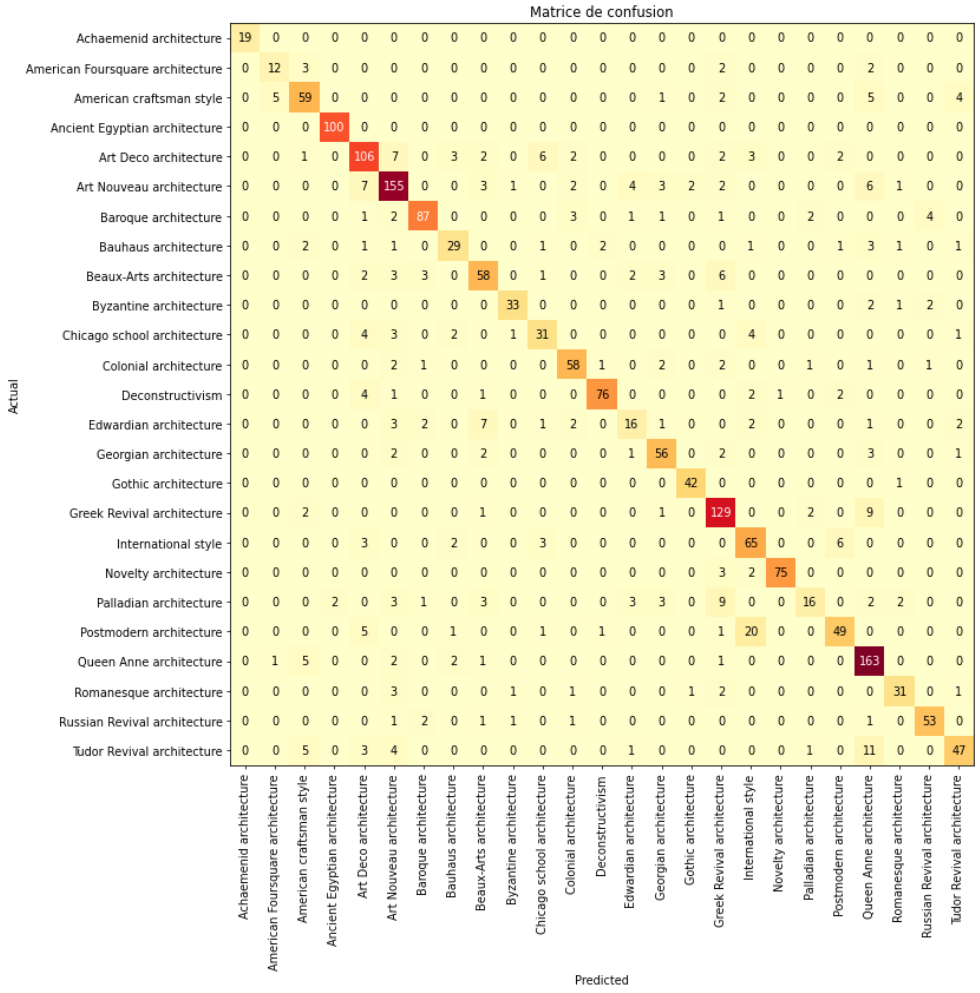

On remarque par exemple que l'architecture Queen Anne est très bien prédite : sur 175 images testées, on en a 163 de bien prédites soit 93% de réussite. Alors que pour l'architecture de l'école de Chicago, on a seulement 66% de réussite.

Afin de tester si l'IA fonctionne, on ajoute sur notre répertoire de travail une image que l'on souhaite prédire, qu'on renomme "imagetest.jpg" puis on exécute les cellules :
prediction,pred_idx,outputs = learn.predict(image) #la modèle d'instance predict(image) renvoie notre prédiction sous la forme d'un objet de la classe Prediction (bibliothèque fastai)
prediction.obj #la méthode obj de prédiction renvoie sous forme de string, la prédiction

En ajoutant la photo du bâtiment Etoile de Télécom SudParis :

On obtient ceci :

```
img = open_image('etoilejpg')
```

```
learn = load_learner(path)
```

```
prediction,pred_idx,outputs = learn.predict(img)
prediction.obj
```

```
'Bauhaus architecture'
```

Ce qui semble être cohérent, ci dessus une image caractéristique de l'architecture Bahaus :

On utilise ensuite le fichier test.py (code source en annexe), puis on spécifie le chemin vers l'image ainsi que le lien vers le fichier export.pkl comme suit :

Test de validation :

On utilise le fichier test.py pour notre test de validation partie back (code source en annexe), puis on spécifie le chemin vers l'image ainsi que le lien vers le fichier export.pkl comme suit :

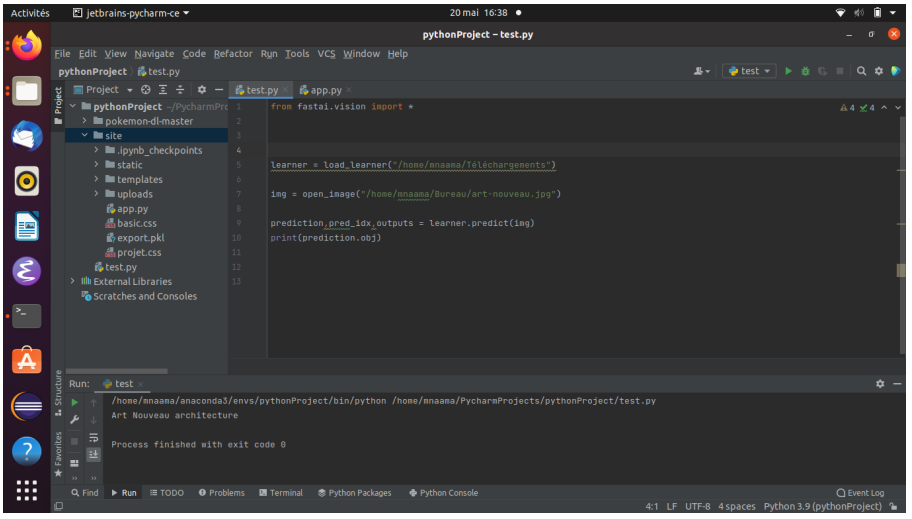

Le code compile bien ("Process finished with exit code0) et on a bien le bon style architectural en sortie ici : Art-Nouveau Architecture.

4) Manuel utilisateur :

Production de l'exécutable :

Réalisation des tests :

Pour le test de la partie back-end : le fichier test.py. On télécharge le fichier export.pkl et on importe une image.

Cf partie sur les tests unitaires

Utilisation :

Pour faire fonctionner le site :

- S'assurer d'avoir dans le même dossier les fichiers et dossiers suivants (dispo sur le gitlab) :
  - app.py
  - basic.css
  - projet.css
  - export.pkl

static dans lequel se trouve :
app.css
dropzone.css
home.css
client.js
dropzone.js

template dans lequel se trouve :
app.html
home.html
solution1.html
__pycache__ dans lequel se trouve :
app.python-38.pyc
uploads ou les images vont finir

- Installer les modules suivants avec pip install :
  imghdr
  os
  Flask
  fastai version 1.0.61 avec la ligne de commande pip install --no-deps fastai==1.0.61
  json

- Pour lancer le code, dans le terminale lancer la commande "flask run" puis contrôle clique sur l'ip fournie ou alors la copier coller dans la barre de recherche d'un navigateur

- Dans le site web cliquer sur "lancer l'application" ou directement aller dans l'onglet app puis glisser l'image à prédir (jpg ou png seulement) puis cliquer sur analyser.

Pour utiliser le script de réseau de neurone :

Pré-requis :
Utiliser un notebook comme GoogleColab permettant d'importer plus facilement les modules suivants : fastai, matplotlib, os.

Suivre les instructions données par les commentaires du code, et exécuter cellule par cellule

5) Conclusion :

L'application Scan'int est le fruit d'un travail en développement Web associé à l'exploitation d'un réseau convolutif de neurones. En effet, l'objectif de ce projet était avant tout de permettre à tout le monde d'utiliser un système de reconnaissance de bâtiments. Notre idée initiale fut la création d'une application mobile. Pour réaliser le prototype nous avons utilisé *kivy* un module python permettant de créer simplement une application tout en y associant notre réseau convolutif lui aussi fait en python. Cependant, nous souhaitions pour notre application un web-design plus évolué et nous nous sommes alors penché sur Swift. Cette possibilité de part des contraintes techniques (outils optimisés pour ios et volumineux) nous a alors poussé à nous tourner vers une application web codée en langage *HTML/CSS* et *JavaScript*. La création du site nécessita donc l'apprentissage de nouveaux langages pour obtenir un design répondant à nos attentes. En parallèle de l'élaboration de la partie front nous avons travaillé sur l'exploitation du réseau de neurones convolutifs. En effet, nous avons eu à cœur de détailler chaque ligne de code nous permettant d'obtenir un fichier de poids

correspondant à notre modèle entraîné. Une fois les parties Back et Front réalisées nous avons été confronté à un problème d'intégration de notre code. Effectivement, nous avons utilisé le module flask de python afin d'héberger localement notre serveur et de lier le back au front. Malheureusement après un long travail d'apprentissage du module nous n'avons pas réussi à lier l'ensemble. Cependant cet échec nous a poussé à développer de nouvelles compétences notamment la compréhension du principe de routes de redirection utilisé dans la création de sites dynamiques.
Le livrable de notre projet n'est donc pas intégralement satisfait, cependant ce dernier nous aura permis de toucher du doigt le métier de développeur, à la fois à travers l'aboutissement d'un livrable comme le front mais aussi aux échecs répétés que tout développeur connaît durant son parcours professionnel.
Pour terminer nous aimerions remercier notre encadrant mais aussi les professeurs de l'école et le club Minet pour leurs aides. De plus, nous souhaiterions dans le futur conclure notre projet et le publier en l'hébergeant dans un serveur externe.

Bibliographie :

Documentation sur Flask : https://flask.palletsprojects.com/en/2.1.x/
Crée des dropzones sur JS : https://cdnout.com/cdn/dropzone@5.7.1/
Documentation sur Fastai : https://docs.fast.ai/
Classfier des images grâce à GoogleColab et Fastai : https://medium.com/unpackai/image-classification-model-using-fastai-and-google-colab-4d77fee8ea9d

Annexe 1:

Gitlab : https://gitlab.com/naamamohamedcpge/pro3600-22-sell-25

Planning prévisionnelle (Trello) : https://trello.com/b/tt4EygPj/pro3600-22-sell-25

Annexe 2 :

Code source de EntraînementIABâtiment.ipynb :

```
"""Entrainement_IA_Bâtiment (2).ipynb


## Importation des modules
"""

# On s'assure que toutes les modifications apportées aux bibliothèques sont automatiquement rechargées ici
# %reload_ext autoreload
# %autoreload 2

# On importe le module matpltlib afin de pouvoir afficher les graphiques pendant nos executions
# %matplotlib inline

#On importe le module files et os qui vont nous être utiles pour la suite du programme.
from google.colab import files
import os

# Le module fastai va nous permettre d'avoir des résultats plus rapidement en termes de DeepLearning
from fastai.vision import *

# Evite les messages d'alertes du à l'obsolescence du module
import warnings
warnings.filterwarnings("ignore", category=UserWarning, module="torch.nn.functional")

## Télécharger le dataset via Kaggle

uploaded = files.upload() #insérer le fichier kaggle.json
```

```
# On créé le  répertoire où l'on va mettre notre dataset
! mkdir -p ~/.kaggle/
! mv kaggle.json ~/.kaggle/

# C'est le chemin, d'accès de notre dataset
chemin = Config.data_path()/'architecture'
chemin.mkdir(parents=True, exist_ok=True)

#On télécharge le dataset
! kaggle datasets download -d wwymak/architecture-dataset


# Une fois bien téléchargé, on le met dans le répertoire, en dezipant
! unzip -q -n architecture-dataset.zip -d {chemin}


# Le chemin de notre data set est celui ci-dessous :
chemin = '/root/.fastai/data/architecture/architectural-styles-dataset'

# On va transformer nos images afin d'augmenter notre dataset
tfms = get_transforms(do_flip=True, flip_vert=False, max_rotate=10, max_zoom=1.1,
                      max_lighting=0.2, max_warp=0.2, p_affine=0.75, p_lighting=0.75)


#Dans cet ensemble de données particulier, les étiquettes sont stockées dans le nom du dossier qui contient les images de chaque classe. Nous devrons les extraire pour pouvoir classer les images dans les bonnes catégories. La bibliothèque fastai a une fonction faite pour cela, `ImageDataBunch.from_folder`.#

data = ImageDataBunch.from_folder(chemin, train=".", valid_pct=0.2,
        ds_tfms=tfms, size=224, num_workers=4, padding_mode='reflection',
bs=64).normalize(imagenet_stats)

#On affiche 9 images de notre set aléatoirement
data.show_batch(rows=3, figsize=(9, 9))

#On regroupe les différentes catégories ensemble.
data.classes, data.c, len(data.train_ds), len(data.valid_ds)




#Retournement (juste horizontal), zoom, lumière, rotation, etc...

def _plot(i,j,ax):
    x,y = data.train_ds[3]
    x.show(ax, y=y)

plot_multi(_plot, 3, 3, figsize=(8,8))
```

```
### Apprentissage

learn = cnn_learner(data, models.resnet34, metrics=[accuracy]) # on va utiliser un réseau de neurones largement utilisé et déjà pré-entraînés sur notre modèle : resnet34. Ce réseau de neurones convolutifs ayant 34 couches de neurones, par la fonction cnn_learner de fastai



#Time = temps pour chaque epoch, donc 4 ici
learn.fit_one_cycle(4)

learn.save('stage-1-resnet34') #Par la fonction .save() de f permet d'enregistrer le réseaux "learn" dans le répertoire courant

interpretation = ClassificationInterpretation.from_learner(learn) #La bibliothèque fastai fournit la classe ClassificationInterpretation, on crée notre objet
#intepretation
interpretation.plot_confusion_matrix(figsize=(12,12), title = "Matrice de confusion", cmap = "YlOrRd", dpi=70) #Méthode d'instance permettant d'afficher
# la matrice de confusion, le coefficient (i,j) de cette matrice affiche combiens de fois le j-ème élement a été prédit alors que la véritable valeur était le i-ème élement

learn.export() #Maintenant on exporte notre modèle dans le dossier root, il est entraîné et doit être utilisé sur des images tests
!cp /root/.fastai/data/architecture/export.pkl . #On le copie dans le répertoire courrant

image = open_image(imagetest.jpg') #On ajoute manuellement, dans le répertoire courant, l'image que l'on veut prédire (à rénommer imagetest impérativement)

learn = load_learner(chemin) #La méthode load_learner de fastai prend en paramètre un chemin et renvoie le modèle dans une variable

prediction,pred_idx,outputs = learn.predict(image) #la modèle d'instance predict(image) renvoie notre prédiction sous la forme d'un objet
#de la classe Prediction (bibliothèque fastai)
prediction.obj #la méthode obj de prediction renvoie sous forme de string, la prédiction
```

Annexe 3 : Code source de app.py

```
import imghdr
from fastai.vision import *
import os
from flask import Flask, render_template, request, redirect, url_for, abort, send_from_directory
from werkzeug.utils import secure_filename
```

```
app = Flask(__name__)
app.config['MAX_CONTENT_LENGTH'] = 2 * 1024 * 1024
app.config['UPLOAD_EXTENSIONS'] = ['.jpg', '.png']
app.config['UPLOAD_PATH'] = 'uploads'

chemin=”/” #Il faut mettre le export.pkl dans le réperoire courant
model = load_learner(chemin)

#=========================validation
image=========================================

def validate_image(stream):
    header = stream.read(512)
    stream.seek(0)
    format = imghdr.what(None, header)
    if not format:
        return None
    return '.' + (format if format != 'jpeg' else 'jpg')

@app.errorhandler(413)
def too_large(e):
    return "File is too large", 413

#=========================mise de l'image dans le dossier============================
@app.route('/')
def home():
    return render_template('/home.html')

@app.route('/app.html')
def index():
    files = os.listdir(app.config['UPLOAD_PATH'])
    return render_template('app.html', files=files)

@app.route('/app.html', methods=['POST'])
def upload_files():
    uploaded_file = request.files['file']
    filename = secure_filename(uploaded_file.filename)
    if filename != '':
        file_ext = os.path.splitext(filename)[1]
        if file_ext not in app.config['UPLOAD_EXTENSIONS'] or \
            file_ext != validate_image(uploaded_file.stream):
            return "Invalid image", 400
        uploaded_file.save(os.path.join(app.config['UPLOAD_PATH'], filename))
    return '', 204



@app.route('/upload', methods=["POST"])
def analyze():

        file = request.files['user-img'].read()
        img = open_image(io.BytesIO(file))
```

```
prediction = model.predict(img)[0]

response = {"result": str(prediction)}
return jsonify(response)
```